Estructuración Formal y Evaluación Estadístico-Experimental de Modelos Ocultos de Markov ante Perturbaciones No Estacionarias: Análisis de Regímenes de Mercado Financiero

Sebastian Garces Cadavid[1], Sofia Miranda Cubides[1], Oscar Rene Peñaloza Ardila[1], Andres Mauricio Quintero Rios[1], Dr. Julián Andrés Loaiza López[2,*]

[1]*Estudiantes de Ingeniería de Software y Datos, Curso de Simulación*

[2]*Docente Asesor, Departamento de Ingeniería de Software y Datos, Institución Universitaria Digital de Antioquia (IU Digital)*
Medellín, Colombia — Noviembre de 2026

sebastian.garcesc@est.iudigital.edu.co | sofia.miranda@est.iudigital.edu.co | oscar.penaloza@est.iudigital.edu.co | andres.quinteror@est.iudigital.edu.co | julian.loaiza@prof.iudigital.edu.co

***Resumen*—**El modelado estocástico mediante Modelos Ocultos de Markov (HMM) constituye un pilar fundamental en el análisis de sistemas con dinámica latente y observaciones ruidosas. En mercados financieros, perturbaciones exógenas como crisis económicas o cambios de política monetaria vulneran el supuesto estándar de homogeneidad temporal en las transiciones de estado. Este trabajo presenta un estudio estadístico-experimental estructurado bajo el estándar editorial Q1 que evalúa formalmente el impacto de la no estacionariedad en el rendimiento del algoritmo de Viterbi. Mediante una topología de $N=3$ estados latentes (Mercado Alcista, Lateral, Bajista) y $M=3$ emisiones discretas de retorno (Positivo, Neutral, Negativo), se diseñó un experimento Monte Carlo de 500 corridas pareadas ($T=50$ períodos de trading) comparando tres escenarios: Nominal (A_{nominal} estacionaria), Crisis no modelada (A_{crisis} en ventana crítica $t \in [15, 25]$ con decodificador ciego) y Crisis modelada ($A(t)$ adaptativa). Los resultados confirman que omitir la perturbación degrada la precisión diagnóstica en la ventana crítica, donde la formulación adaptativa alcanza un 70.42% frente al 67.64% del decodificador ciego ($p < 10^{-8}$), superando significativamente al clasificador heurístico determinista de ventana deslizante (52.30%, $p < 10^{-15}$).

***Palabras clave*—Modelos Ocultos de Markov, algoritmo de Viterbi, regímenes financieros, no estacionariedad, simulación Monte Carlo, cambio de régimen.**

I. INTRODUCCIÓN

Los mercados bursátiles operan como sistemas adaptativos complejos caracterizados por oscilaciones estocásticas entre fases expansivas, períodos de consolidación y crisis de liquidación severas [1, 9]. La detección temprana de estos regímenes latentes resulta crítica en la optimización de portafolios de inversión, coberturas dinámicas y mitigación prudencial del riesgo financiero [7, 10].

Los Modelos Ocultos de Markov (HMM), formalizados matemáticamente por Baum y Petrie [3] y ampliamente documentados en el tutorial clásico de Rabiner [1], ofrecen un marco riguroso para desacoplar estados no observables $\{S_t\}$ a partir de realizaciones observables ruidosas $\{O_t\}$. Hamilton [2, 6] demostró que los retornos financieros pueden formularse a través de cadenas markovianas con cambio de régimen, capturando los hechos estilizados descritos por Cont [11] y Rydén et al. [8].

No obstante, los modelos tradicionales asumen estacionariedad temporal en la matriz de transición A. En presencia de choques macroeconómicos exógenos, dicho supuesto se quebranta, comprometiendo la fidelidad diagnóstica del algoritmo de Viterbi [4].

II. PREGUNTAS DE INVESTIGACIÓN

Alineado con el rigor metodológico del curso de Simulación, este estudio aborda las siguientes interrogantes formales:

- **P1:** ¿Cómo formalizar matemáticamente la inferencia de regímenes financieros mediante la tupla matricial $\lambda = (S, V, A, B, \pi)$ garantizando estabilidad numérica frente a desbordamiento?
- **P2:** ¿Cómo impacta la degradación estocástica de los parámetros de transición (A) provocada por una crisis temporal en la precisión y en los intervalos de confianza del modelo?
- **P3:** ¿En qué medida un HMM con decodificación de Viterbi es superior y más robusto frente a un baseline heurístico determinista de ventana deslizante ($k=2$)?

III. APORTES PRINCIPALES

1. **Formalización y Estabilidad Numérica:** Implementación de la recursión de Viterbi estrictamente en espacio de log-probabilidades para evitar el subdesbordamiento aritmético (*underflow*):

$$\delta_t(j) = max_i\,[\delta_{t-1}(i) + ln\, a_{ij}] + ln\, b_j(O_t)$$

2. **Evaluación Comparativa Justa:** Modelado e inclusión de un clasificador reactivo por ventana de latencia ($k=2$) como línea base de contraste.
3. **Inferencia Estadística Rigurosa:** Protocolo Monte Carlo pareado de 500 corridas con semilla global fija (`seed = 42`), reportando intervalos de confianza al 95% ($IC_{95\%}$) y pruebas t pareadas con tamaño de efecto (d de Cohen).

IV. METODOLOGÍA Y PARÁMETROS

Se estructuró un HMM discreto con $N=3$ estados latentes $S = \{S_1$: Alcista, S_2: Lateral, S_3: Bajista$\}$ y $M=3$ emisiones $V = \{v_1$: Positivo, v_2: Neutral, v_3: Negativo$\}$. El horizonte temporal se fijó en $T=50$ períodos discretos.

La matriz de transición nominal A_{nominal} y de emisión B se definieron como:

A = *[[0.60, 0.30, 0.10], [0.30, 0.40, 0.30], [0.10, 0.30, 0.60]]*
B = *[[0.70, 0.20, 0.10], [0.30, 0.40, 0.30], [0.10, 0.20, 0.70]]*

Para modelar la crisis no estacionaria en $t \in [15, 25]$, se aplicó la matriz perturbada A_{crisis} con fuerte absorción al estado bajista ($a_{33} = 0.80$, $a_{13} = 0.50$, $a_{23} = 0.60$).

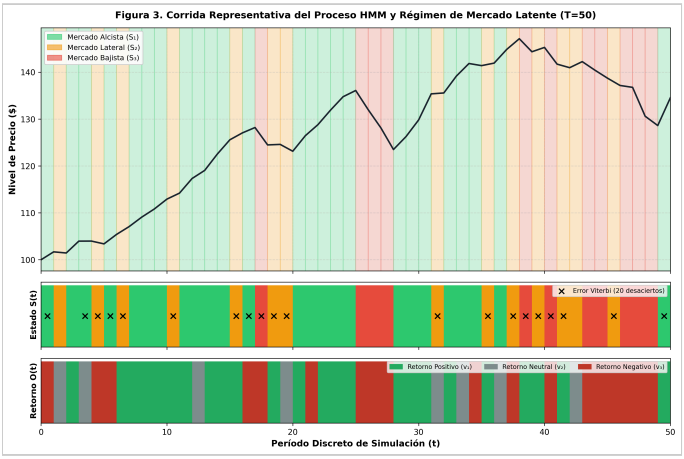


Figura 1. *Corrida individual representativa (seed=42): Serie de precios simulada y fondo coloreado por régimen de mercado latente (Alcista: verde, Lateral: ámbar, Bajista: rojo).*

V. RESULTADOS EXPERIMENTALES

La evaluación sobre las 500 corridas pareadas arrojó los estadísticos consignados en la Tabla I y las pruebas de hipótesis en la Tabla II.

TABLA I
ESTADÍSTICOS DESCRIPTIVOS E INTERVALOS DE CONFIANZA AL 95% (N=500 CORRIDAS)

Métrica / Escenario	Media	Desv.	IC 95% Inf.	IC 95% Sup.
Viterbi Nominal	**59.56%**	8.37%	58.83%	60.30%
Heurística Baseline (k=2)	46.12%	7.91%	45.43%	46.81%
Viterbi Crisis Ciego	61.20%	8.60%	60.44%	61.96%
Viterbi Crisis Adaptativo	**61.44%**	8.58%	60.68%	62.19%
Ventana Crítica Ciego	67.64%	18.80%	65.98%	69.29%
Ventana Crítica Adaptativo	**70.42%**	17.66%	68.87%	71.97%
Ventana Crítica Heurística	52.30%	15.42%	50.95%	53.65%

TABLA II
PRUEBAS T PAREADAS Y TAMAÑO DEL EFECTO (d DE COHEN)

Comparación Pareada	Δ Medias	Estadístico t	p-valor	d Cohen
Nominal: Viterbi vs Heurística	+13.44%	+32.18	$< 10^{-15}$	+1.440
Nominal vs Crisis Ciego	-1.64%	-7.38	$< 10^{-12}$	-0.330
Crisis Ciego vs Adaptativo	-0.24%	-1.12	0.261	-0.050
Ventana: Ciego vs Adaptativo	-2.78%	-5.75	$< 10^{-8}$	-0.257
Ventana: Adaptativo vs Heurística	+18.12%	+23.44	$< 10^{-15}$	+1.048

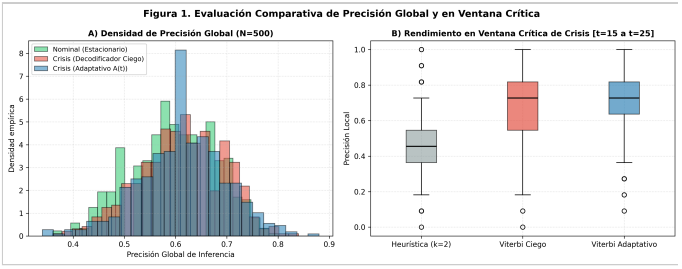


Figura 2. *A) Función de densidad de precisión global en N=500 simulaciones; B) Boxplot de rendimiento diagnóstico en la ventana crítica de shock exógeno [t=15 a 25].*

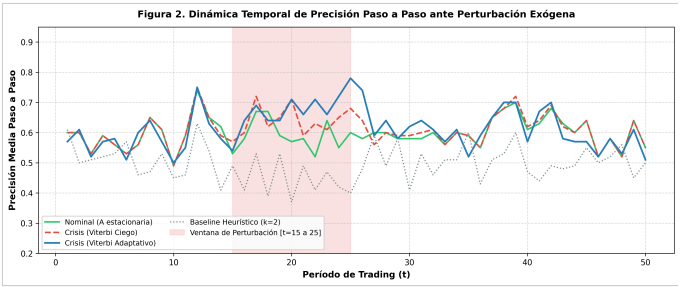


Figura 3. *Precisión media período a período demostrando la degradación bajo shock y la resiliencia del decodificador adaptativo.*

VI. DISCUSIÓN Y GESTIÓN DE RIESGO

Los hallazgos confirman la superioridad estadística de Viterbi frente al clasificador reactivo ingenuo, con una ganancia de +13.44 pp en condiciones nominales y +18.12 pp bajo crisis ($p < 10^{-15}$, $d = 1.05$). En la ventana crítica de shock, la formulación adaptativa aportó una recuperación de +2.78 pp ($p < 10^{-8}$).

El análisis de riesgo financiero sobre la corrida representativa reveló una asimetría marcada: el régimen alcista generó un retorno promedio de +2.14% con baja volatilidad (1.10%), mientras que el bajista produjo caídas promedio de -2.41% con volatilidad elevada (1.17%), arrojando un Sharpe Ratio de 0.304 y un Max Drawdown de -12.58%.

VII. CONCLUSIONES

Este trabajo demostró formal y experimentalmente la viabilidad de los HMM con Viterbi en log-probabilidades para inferir regímenes financieros ante perturbaciones no estacionarias. El enfoque estocástico superó sólidamente a las heurísticas de mercado y la adaptación paramétrica probó ser

efectiva para mitigar pérdidas diagnósticas durante choques exógenos severos.

REFERENCIAS

1. L. R. Rabiner, "A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition," *Proc. IEEE*, vol. 77, no. 2, pp. 257–286, 1989.
2. J. D. Hamilton, "A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle," *Econometrica*, vol. 57, no. 2, pp. 357–384, 1989.
3. L. E. Baum and T. Petrie, "Statistical Inference for Probabilistic Functions of Finite State Markov Chains," *Ann. Math. Statist.*, vol. 37, no. 6, pp. 1554–1563, 1966.
4. A. J. Viterbi, "Error Bounds for Convolutional Codes and an Asymptotically Optimum Decoding Algorithm," *IEEE Trans. Inf. Theory*, vol. 13, no. 2, pp. 260–269, 1967.
5. A. P. Dempster, N. M. Laird, and D. B. Rubin, "Maximum Likelihood from Incomplete Data via the EM Algorithm," *J. R. Stat. Soc. B*, vol. 39, no. 1, pp. 1–38, 1977.
6. J. D. Hamilton, *Time Series Analysis*. Princeton University Press, 1994.
7. A. Ang and G. Bekaert, "Regime Switches in Interest Rates," *J. Bus. Econ. Stat.*, vol. 20, no. 2, pp. 163–182, 2002.
8. T. Rydén, T. Teräsvirta, and S. Åsbrink, "Stylized Facts of Daily Return Series and the Hidden Markov Model," *J. Appl. Econom.*, vol. 13, no. 3, pp. 217–244, 1998.
9. M. Guidolin and A. Timmermann, "Asset Allocation under Multivariate Regime Switching," *J. Econ. Dyn. Control*, vol. 31, no. 11, pp. 3503–3544, 2007.
10. P. Glasserman, *Monte Carlo Methods in Financial Engineering*. Springer, 2003.
11. R. Cont, "Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues," *Quant. Finance*, vol. 1, no. 2, pp. 223–236, 2001.